PAPER GRANNY

arXiv Paper Interpretation Agent

深度残差学习用于图像识别

论文深度解读

日期：2024 年 1 月

论文信息

原文：arXiv:1512.03385

作者：Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun (Microsoft Research)

发表：CVPR 2016 (Oral)

目录

1 背景知识 **2**

1.1 深度学习的"深度困境" 2

1.2 已有的解决方案及其局限 2

2 核心问题与创新思路 **3**

2.1 核心问题 3

2.2 关键洞察 3

2.3 创新思路：残差学习 3

3 方法详解 **4**

3.1 残差学习框架 4

3.1.1 数学表达 4

3.1.2 网络结构 4

3.2 网络架构设计 5

3.2.1 基础网络（Plain Network） 5

3.2.2 残差网络（Residual Network） 5

3.2.3 瓶颈架构（Bottleneck Architecture） 7

3.3 不同深度的 ResNet 架构 8

4 实验结果 **8**

4.1 ImageNet 图像分类 8

4.1.1 退化问题的验证 8

4.1.2 与最先进方法的对比 9

4.2 CIFAR-10 实验：探索极限深度 9

4.3 残差函数的分析 11

4.4 目标检测任务 11

5 总结 **12**

5.1 核心贡献 12

5.2 为什么残差学习有效？ 12

5.3 局限性与未来方向 13

6 参考资料 **13**

1 背景知识

1.1 深度学习的"深度困境"

在 2015 年之前，深度学习领域面临一个令人困惑的现象：

反直觉的现象

理论上，更深的网络应该能学到更复杂的特征，表现应该更好。但实验发现：

- 网络深度增加到一定程度后，训练误差反而上升
- 这不是过拟合（过拟合是训练误差低、测试误差高）
- 更深的网络连训练集都拟合不好！

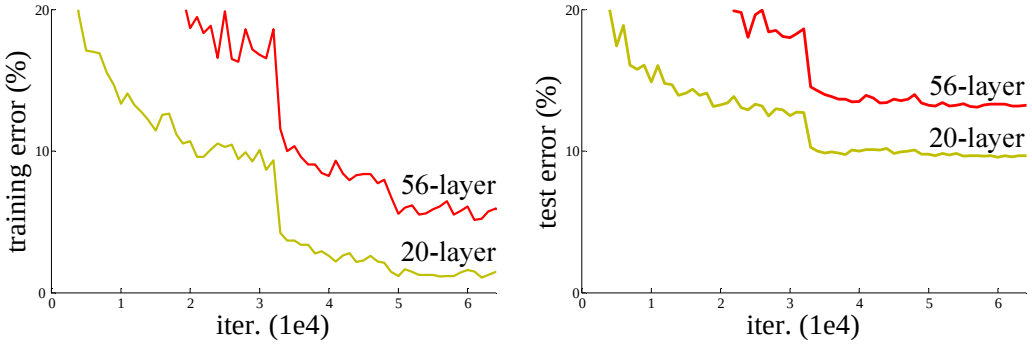

图 1: 【原论文图 1】退化问题的实证：在 CIFAR-10 数据集上，56 层网络（虚线）的训练误差和测试误差都比 20 层网络（实线）更高。

为什么这很奇怪?

想象你要盖一栋楼：

- 你已经有一个 20 层的楼（浅层网络）
- 现在要盖一个 56 层的楼（深层网络）
- 理论上，你可以在 20 层的基础上再加 36 层，新加的层什么都不做（恒等映射），这样 56 层的楼至少不会比 20 层的差
- 但实际上，神经网络却做不到这一点！

这说明：现有的训练方法很难让深层网络学到"恒等映射"这种简单的变换。

1.2 已有的解决方案及其局限

在残差网络出现之前，人们尝试了多种方法：

梯度消失/爆炸问题

问题：反向传播时，梯度会逐层衰减或爆炸，导致前面的层几乎无法更新。
解决方案：

- 归一化初始化（Xavier 初始化、He 初始化）
- 批归一化（Batch Normalization）

效果：可以训练几十层的网络，但退化问题依然存在。

2 核心问题与创新思路

2.1 核心问题

论文要解决的问题

如何训练极深的神经网络（超过 100 层），并从中获得性能提升？

2.2 关键洞察

作者提出了一个深刻的观察：

恒等映射假设

假设一个浅层网络已经学到了很好的特征。现在我们要构建一个更深的网络，可以在浅层网络上加一些新层。
如果新加的层能学到"恒等映射"（即输出等于输入，什么都不做），那么深层网络的性能至少不会比浅层网络差。

但实验表明：现有的训练方法很难学到恒等映射！

2.3 创新思路：残差学习

作者的解决方案非常巧妙：

核心思想：让网络学习"残差"

传统方法：让网络直接学习映射 $\mathcal{H}(x)$
残差方法：让网络学习残差函数 $\mathcal{F}(x) = \mathcal{H}(x) - x$

然后通过 $\mathcal{H}(x) = \mathcal{F}(x) + x$ 得到最终结果。

关键优势：如果恒等映射是最优解，那么只需让 $\mathcal{F}(x) \to 0$，这比让网络直接学习恒等映射容易得多！

生活中的类比

想象你要教一个学生解题：

- **传统方法**：让学生从零开始写出完整答案
- **残差方法**：先给他一个参考答案（恒等映射），让他只需要学习"如何改进这个答案"

如果参考答案已经很好了，学生只需要学会"不做任何改动"（残差为 0），这比从零开始写答案容易得多。

3 方法详解

3.1 残差学习框架

3.1.1 数学表达

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \tag{1}$$

公式拆解

- $\mathbf{x}$：输入向量（来自前一层的特征）
- $\mathbf{y}$：输出向量（传递给下一层的特征）
- $\mathcal{F}(\mathbf{x}, \{W_i\})$：残差函数，由若干层网络学习得到
- $+\mathbf{x}$：跳跃连接（shortcut connection），直接把输入加到输出上

3.1.2 网络结构

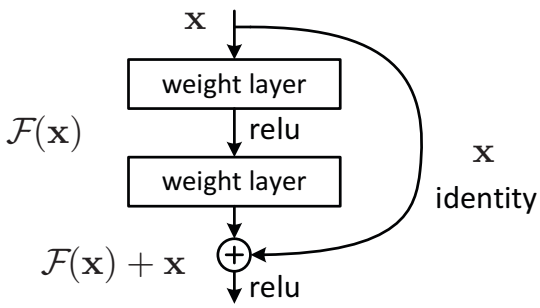

图 2: 【原论文图 2】残差学习的基本构建块。输入 $\mathbf{x}$ 通过两条路径：(1) 经过权重层学习残差 $\mathcal{F}(\mathbf{x})$；(2) 直接跳跃连接。两条路径的输出相加得到最终输出。

关键设计

- **跳跃连接**：直接把输入 $\mathbf{x}$ 加到输出上，不增加任何参数
- **残差学习**：网络只需要学习"残差"（对输入的修正），而不是完整映射
- **易于优化**：如果恒等映射是最优的，网络只需把 $\mathcal{F}$ 的权重推向 0 即可

3.2 网络架构设计

3.2.1 基础网络（Plain Network）

作者首先设计了一个基础网络架构：

设计原则

- 主要使用 3×3 卷积层
- 相同输出特征图尺寸的层，有相同数量的滤波器
- 特征图尺寸减半时，滤波器数量加倍（保持时间复杂度）
- 通过步长为 2 的卷积进行下采样

3.2.2 残差网络（Residual Network）

在基础网络上添加跳跃连接：

PAPER GRANNY
arXiv Paper Interpretation Agent

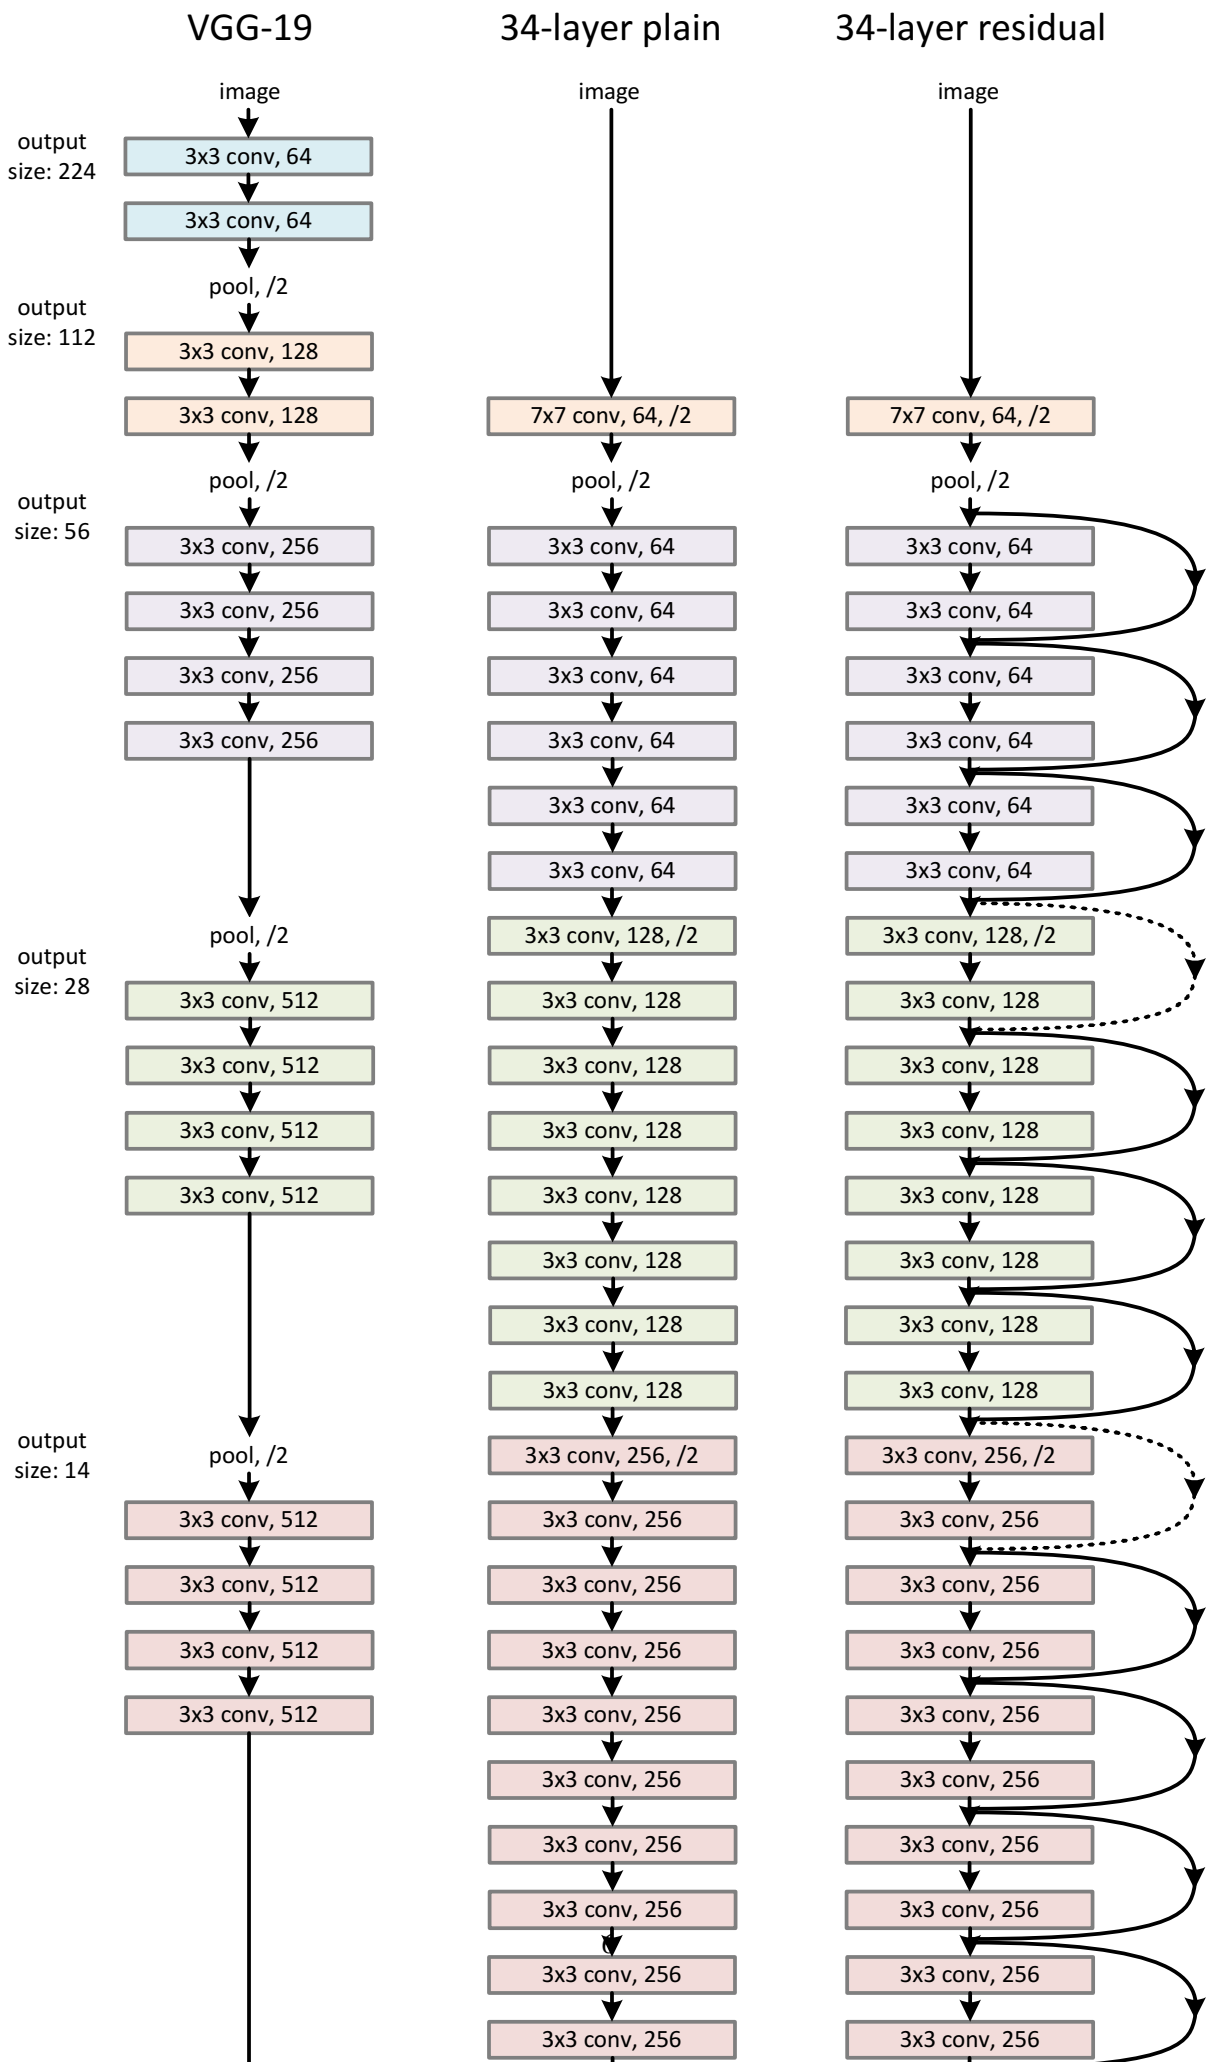

两种跳跃连接方式

情况 1：维度相同（实线连接）

$$\mathbf{y} = \mathcal{F}(\mathbf{x}) + \mathbf{x} \tag{2}$$

直接相加，不增加参数。

情况 2：维度不同（虚线连接）

$$\mathbf{y} = \mathcal{F}(\mathbf{x}) + W_s\mathbf{x} \tag{3}$$

使用 1×1 卷积调整维度，增加少量参数。

3.2.3 瓶颈架构（Bottleneck Architecture）

对于更深的网络（50 层以上），作者设计了瓶颈块：

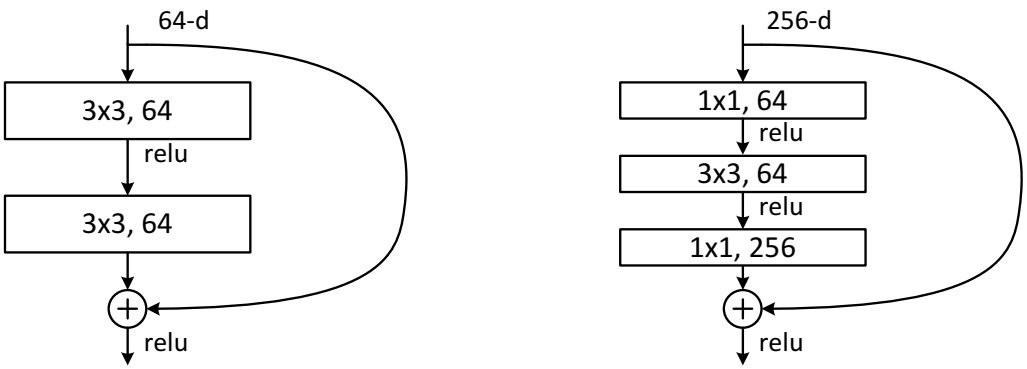

图 4: 【原论文图 4】两种残差块设计。左：基础块（用于 ResNet-34）；右：瓶颈块（用于 ResNet-50/101/152）。瓶颈块使用 1×1 卷积先降维再升维，减少计算量。

为什么叫"瓶颈"?

想象一个沙漏：

- 输入维度高（256 维）→ 中间维度低（64 维）→ 输出维度高（256 维）
- 中间窄的部分就是"瓶颈"
- 这样设计可以大幅减少计算量

3.3 不同深度的 ResNet 架构

层名称	输出尺寸	18 层	34 层	50 层	101 层
conv1	112×112	7×7, 64, stride 2			
conv2_x	56×56	3×3 最大池化, stride 2			
		$[3 \times 3, 64] \times 2$	$[3 \times 3, 64] \times 3$	瓶颈 $\times 3$	瓶颈 $\times 3$
conv3_x	28×28	$[3 \times 3, 128] \times 2$	$[3 \times 3, 128] \times 4$	瓶颈 $\times 4$	瓶颈 $\times 4$
conv4_x	14×14	$[3 \times 3, 256] \times 2$	$[3 \times 3, 256] \times 6$	瓶颈 $\times 6$	瓶颈 $\times 23$
conv5_x	7×7	$[3 \times 3, 512] \times 2$	$[3 \times 3, 512] \times 3$	瓶颈 $\times 3$	瓶颈 $\times 3$
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9

表 1: 不同深度 ResNet 的架构配置

重要发现

ResNet-152 虽然深度是 VGG-19 的 8 倍，但计算量（11.3B FLOPs）反而更低（VGG-19 为 19.6B FLOPs）！

4 实验结果

4.1 ImageNet 图像分类

4.1.1 退化问题的验证

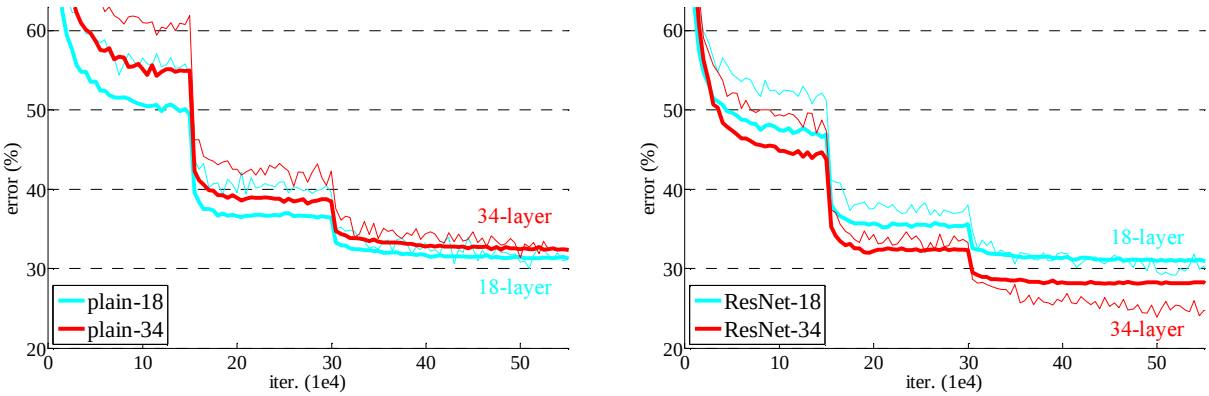

图 5: 【原论文图 4】ImageNet 训练曲线。左：基础网络（plain networks），34 层（虚线）比 18 层（实线）误差更高；右：残差网络，34 层（虚线）比 18 层（实线）误差更低。

关键观察

基础网络：

- 34 层网络训练误差比 18 层更高
- 说明退化问题确实存在

残差网络：

- 34 层网络训练误差比 18 层更低
- 退化问题被成功解决！
- 更深的网络确实能学到更好的特征

4.1.2 与最先进方法的对比

模型	Top-1 错误率	Top-5 错误率
VGG-16	28.07%	9.33%
GoogLeNet	-	9.15%
PReLU-net	24.27%	7.38%
ResNet-34	24.52%	7.46%
ResNet-50	22.85%	6.71%
ResNet-101	21.75%	6.05%
ResNet-152	**21.43%**	**5.71%**
ResNet 集成	-	**3.57%**

表 2: ImageNet 验证集上的错误率（单模型结果，10-crop 测试）

里程碑式的成果

- ResNet-152 单模型 Top-5 错误率：**5.71%**
- ResNet 集成模型 Top-5 错误率：**3.57%**
- **赢得 ILSVRC 2015 图像分类冠军！**
- 比前一年的最佳成绩（GoogLeNet 6.66%）提升了近一半

4.2 CIFAR-10 实验：探索极限深度

作者在 CIFAR-10 数据集上探索了更深的网络：

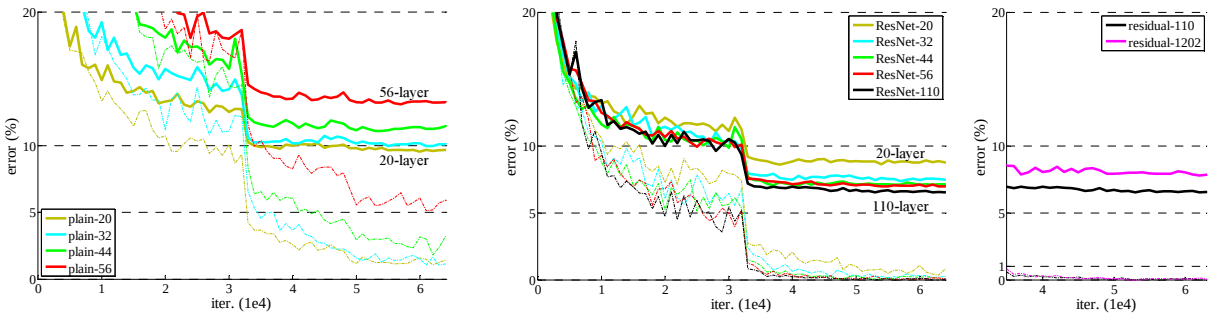

图 6: 【原论文图 5】CIFAR-10 训练曲线。左：基础网络，深层网络表现更差；中：残差网络，深层网络表现更好；右：110 层和 1202 层残差网络的对比。

模型	参数量	测试错误率
Highway (32 层)	1.25M	8.80%
ResNet-20	0.27M	8.75%
ResNet-32	0.46M	7.51%
ResNet-44	0.66M	7.17%
ResNet-56	0.85M	6.97%
ResNet-110	1.7M	**6.43%**
ResNet-1202	19.4M	7.93%

表 3: CIFAR-10 测试集上的错误率

1000+ 层网络的发现

- 1202 层网络可以成功训练（训练误差 <0.1%）
- 但测试错误率（7.93%）比 110 层网络（6.43%）更高
- 原因：过拟合（CIFAR-10 只有 5 万张训练图片，但模型有 1940 万参数）

4.3 残差函数的分析

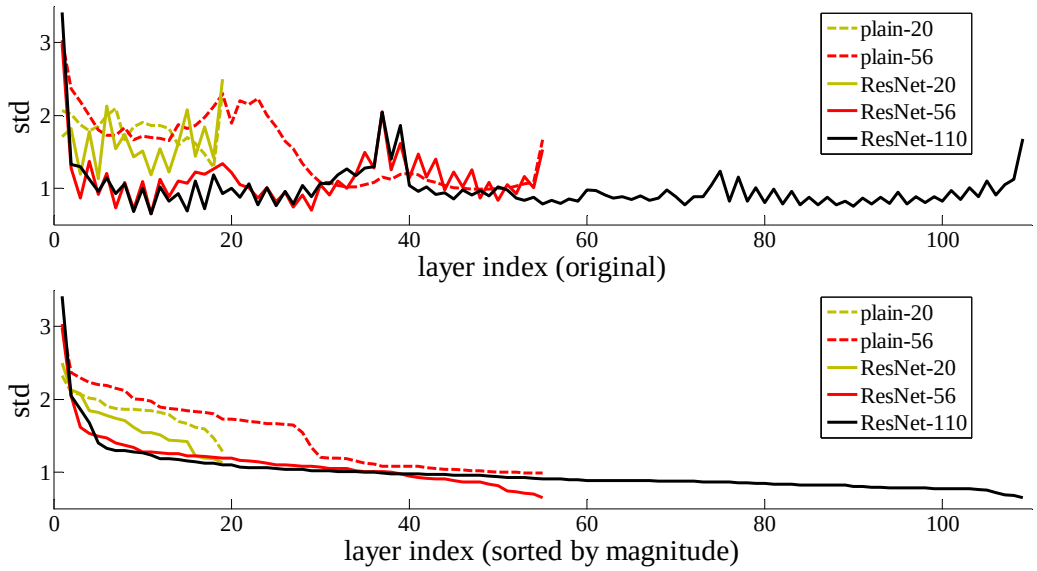

图 7: 【原论文图 6】各层响应的标准差。残差网络的响应普遍比基础网络小，说明残差函数确实学到了"接近零"的修正。

为什么残差网络的响应更小?

- 残差网络学习的是 $\mathcal{F}(x) = H(x) - x$
- 如果恒等映射已经很好，那么 $\mathcal{F}(x)$ 应该接近 0
- 实验验证：残差网络的层响应确实很小
- 这说明网络主要是在"微调"输入，而不是从零开始学习

4.4 目标检测任务

残差网络学到的特征具有很好的泛化能力:

模型	PASCAL VOC	MS COCO
VGG-16	73.2% mAP	21.2% mAP
ResNet-101	**76.4**% mAP	**27.2**% mAP

表 4: 目标检测性能对比（使用 Faster R-CNN）

跨任务的突破

ResNet-101 在 MS COCO 数据集上：

- mAP@[.5, .95] 提升了 6.0%（相对提升 28%）
- 这个提升完全归功于更好的网络架构
- 检测方法完全相同，只是换了骨干网络

5 总结

5.1 核心贡献

三大贡献

1. **发现退化问题**：首次系统性地揭示并验证了深层网络的退化问题
2. **提出残差学习**：
   - 让网络学习残差函数 $\mathcal{F}(x) = H(x) - x$
   - 通过跳跃连接实现恒等映射
   - 不增加参数，不增加计算量
3. **突破深度极限**：
   - 成功训练 152 层网络（ImageNet）
   - 成功训练 1202 层网络（CIFAR-10）
   - 赢得 ILSVRC 2015 多项冠军

5.2 为什么残差学习有效?

直观理解

问题：让神经网络学习恒等映射 $H(x) = x$ 很难
解决：让神经网络学习残差 $\mathcal{F}(x) = 0$ 很容易

原因：

- 如果初始化接近 0，网络很容易保持接近 0
- 如果要学习恒等映射，需要精确调整所有权重
- 残差学习提供了更好的" 前置条件"

5.3 局限性与未来方向

局限性

- 极深网络（1202 层）在小数据集上容易过拟合
- 需要配合批归一化（Batch Normalization）使用
- 跳跃连接在维度不匹配时需要投影，会增加参数

后续影响

ResNet 成为深度学习领域的里程碑：

- 被广泛应用于计算机视觉、自然语言处理等领域
- 启发了 DenseNet、Wide ResNet 等改进架构
- 跳跃连接思想被 Transformer 等架构采用
- 成为现代深度神经网络的标配组件

6 参考资料

原论文

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. *Deep Residual Learning for Image Recognition*. CVPR 2016.

arXiv: 1512.03385

关键引用

- VGGNet: Simonyan & Zisserman, 2014
- Batch Normalization: Ioffe & Szegedy, 2015
- Highway Networks: Srivastava et al., 2015
- ImageNet: Russakovsky et al., 2014