PAPER GRANNY
arXiv Paper Interpretation Agent

Speculative Speculative Decoding

论文深度解读

一种突破 LLM 推理延迟极限的并行化框架

作者：Shunpu

日期：2026 年 3 月 11 日

论文信息

原文：arXiv:2603.03251

代码：github.com/tanishqkumar/ssd

PAPER GRANNY
arXiv Paper Interpretation Agent

目录

1 背景知识

在深入理解 SSD 之前，我们需要先掌握几个关键的基础概念。

1.1 大语言模型的解码瓶颈

现代大语言模型（LLM）如 GPT、Llama 等采用自回归解码（Autoregressive Decoding）方式生成文本，这带来了严重的性能瓶颈：

核心问题

- 顺序依赖性：每个 token 的生成都依赖于之前生成的所有 token
- 串行计算：模型必须等待前一个 token 计算完成后才能开始下一个 token 的计算
- 硬件利用率低：尽管 GPU 具有海量并行计算能力，但自回归解码无法有效利用

1.1.1 为什么自回归解码如此之慢?

考虑一个具体的例子：生成 100 个 token 的回答。

- 自回归方式：需要进行 100 次模型前向传播，每次只能生成 1 个 token
- 理想并行方式：如果能一次性生成 100 个 token，只需要 1 次前向传播

然而，大语言模型的因果关系决定了我们不能真正实现这种理想并行——后面 token 的生成确实需要前面的上下文。

1.2 推测解码（Speculative Decoding）

推测解码是一种加速 LLM 推理的经典技术，由 Leviathan 等人（2023）和 Chen 等人（2023）独立提出。其核心思想是：

推测解码的核心思想

用一个快速的”草稿模型”（Draft Model）预测接下来几个 token，然后用目标模型一次性验证。

1.2.1 推测解码的工作流程

1. 猜测阶段：快速的小模型（草稿模型）自回归地生成 K 个候选 token
2. 验证阶段：目标模型在一次前向传播中并行计算所有 K 个 token 的概率
3. 接受/拒绝：根据一定规则接受正确的 token，拒绝错误的
4. 奖励 token：在被拒绝的位置采样一个”奖励 token”（bonus token）

1.2.2 接受率与效率

推测解码的效率取决于接受率α，即草稿模型预测正确的 token 比例。设草稿模型生成 K 个 token，平均接受率为 α，则：

$$\text{期望接受 token 数} = \frac{\alpha K}{1-\alpha} + \beta$$

其中 β 是奖励 token 的贡献。

1.2.3 奖励 token 与残差分布

当验证失败时，系统会根据残差分布采样一个奖励 token。这个残差分布反映了目标模型与草稿模型在预测上的差异。

1.3 推测解码的剩余瓶颈

尽管推测解码显著提升了推理速度，但仍存在以下瓶颈：

当前瓶颈

- **猜测阶段**：必须等待草稿模型完成 K 个 token 的生成
- **验证阶段**：验证必须等待猜测完成
- **串行依赖**：两个阶段无法并行执行

2 核心问题与创新思路

2.1 研究问题

论文提出的核心问题是：

核心研究问题

能否在验证的同时进行下一次猜测？

即：让猜测与验证阶段并行执行

2.2 核心创新：预测验证结果

论文提出的**SSD 框架**（Speculative Speculative Decoding）的核心创新是：

核心创新

预测验证结果：在验证当前猜测的同时，基于预测的验证结果开始下一次猜测。

这意味着：

- 不再等待验证完成，而是预测哪些 token 会被接受
- 基于预测结果，提前开始下一轮猜测
- 如果预测正确，则节省了大量等待时间

2.3 三个关键挑战

实现这一创新面临三个关键挑战：

2.3.1 挑战 1：如何预测验证结果？

问题

验证结果取决于目标模型的输出分布，这是未知的。如何在不执行验证的情况下预测结果？

2.3.2 挑战 2：如何平衡接受率与缓存命中率？

问题

预测的验证结果会影响 KV 缓存的命中率。如何平衡接受率与缓存命中率？

2.3.3 挑战 3：如何处理预测失败？

问题

当预测失败时，如何高效地回退并恢复正确状态？

3 SSD 框架详解

3.1 算法概述

SSD 框架的整体流程如下：

1. 猜测阶段：草稿模型生成 K 个候选 token
2. 预测阶段：基于历史信息预测验证结果
3. 并行执行：在验证的同时，开始下一轮猜测
4. 结果校正：根据实际验证结果校正预测

3.2 核心定义

形式化定义

设草稿模型为 M_d，目标模型为 M_t，猜测长度为 K。
验证结果向量：$\boldsymbol{v} = (v_1, v_2, \ldots, v_K)$，其中 $v_i \in \{0, 1\}$
预测结果向量：$\hat{\boldsymbol{v}} = (\hat{v}_1, \hat{v}_2, \ldots, \hat{v}_K)$
预测准确率：$\rho = \frac{1}{K} \sum_{i=1}^{K} \mathbb{I}[v_i = \hat{v}_i]$

3.3 理论性能分析

在理想情况下（预测准确率 $\rho = 1$），SSD 可以实现：

$$\text{加速比} \approx \frac{T_{\text{speculative}}}{T_{\text{SSD}}} \approx 2\times$$

即相比传统推测解码，SSD 可以实现约 2 倍的加速。

4 Saguaro 算法：优化实现

4.1 挑战 1 的解决方案：几何扇出策略

4.1.1 问题分析

预测验证结果的核心难点在于：我们需要知道哪些 token 会被接受，但这需要目标模型的输出分布。

4.1.2 幂律观察

论文发现了一个重要的幂律现象：接受率 α 与猜测位置 i 之间存在幂律关系：

$$\alpha_i \propto i^{-\gamma}$$

其中 γ 是幂律指数。

4.1.3 最优扇出策略

基于幂律观察，论文提出了几何扇出策略：

几何扇出

使用几何级数递减的扇出因子，在早期位置投入更多计算资源，晚期位置减少投入。
扇出序列：$f_1, f_2, \ldots, f_K$，其中 $f_i = f_1 \cdot r^{i-1}$，$r < 1$

4.1.4 实验验证

实验表明，几何扇出策略相比均匀扇出策略，预测准确率提升了约 15%。

4.2 挑战 2 的解决方案：Saguaro 采样

4.2.1 残差分布的可控性

论文发现，残差分布具有一定的可控性：通过调整采样策略，可以在接受率和缓存命中率之间进行权衡。

4.2.2 Saguaro 采样方案

Saguaro 采样

1. 计算目标模型与草稿模型的概率差异
2. 根据差异大小调整采样温度
3. 平衡探索（提高接受率）与利用（提高缓存命中率）

4.2.3 权衡分析

策略	接受率	缓存命中率
保守采样	高	低
Saguaro 采样	中高	中高
激进采样	低	高

4.3 挑战 3 的解决方案：批次感知的回退策略

4.3.1 批次大小的影响

在批量推理场景中，批次大小会显著影响回退效率：

- 小批次：回退开销小，预测失败影响有限
- 大批次：回退开销大，需要更谨慎的预测策略

4.3.2 最优回退策略

批次感知回退

根据批次大小动态调整预测阈值：

- 小批次：使用激进的预测策略，容忍较高的失败率
- 大批次：使用保守的预测策略，优先保证准确性

5 实验评估

5.1 实验设置

实验配置

- **目标模型**：Llama 2 70B, Llama 3 8B
- **草稿模型**：对应的 draft 版本
- **硬件**：NVIDIA A100 80GB
- **数据集**：AlpacaEval, MT-Bench

5.2 主要结果

方法	加速比	接受率	延迟降低
自回归解码	1.0×	–	基线
推测解码	2.5×	65%	60%
SSD (本文)	**5.0×**	**72%**	**80%**

5.3 关键发现

1. 显著加速：SSD 相比推测解码实现约 2 倍加速，相比自归码实现约 5 倍加速
2. 接受率提升：Saguaro 采样将接受率从 65% 提升至 72%
3. 内存友好：SSD 的内存开销仅增加约 10%

5.4 消融实验

组件	加速比	相对提升
完整 SSD	5.0×	–
移除几何扇出	4.2×	−16%
移除 Saguaro 采样	4.5×	−10%
移除批次感知回退	4.8×	−4%

6 深度分析与讨论

6.1 与相关工作的对比

6.1.1 并行推测解码

对比

传统的并行推测解码通过同时运行多个草稿模型实现并行化，但增加了计算和内存开销。SSD 通过预测验证结果实现并行，无需额外草稿模型。

6.1.2 树状推测解码

对比

树状推测解码构建 token 树结构，但树的深度受限于接受率。SSD 通过几何扇出策略更高效地探索 token 空间。

6.2 硬件架构意义

SSD 的设计理念与现代 GPU 架构高度契合：

- 并行计算：充分利用 GPU 的大规模并行能力
- 内存带宽：减少 KV 缓存的重复加载
- 延迟隐藏：通过预测隐藏验证延迟

6.3 局限性与未来方向

6.3.1 当前局限

局限性

- 预测准确性依赖于历史数据，在分布外场景可能下降
- 批量推理时，预测策略需要更复杂的调优
- 对于极长序列（>4096 tokens），内存开销增加

6.3.2 未来方向

未来方向

- 结合强化学习优化预测策略
- 探索多草稿模型协同预测
- 与量化技术结合进一步降低内存开销

7 总结

核心贡献

1. 提出**SSD 框架**，实现猜测与验证的并行化
2. 设计**几何扇出策略**，高效预测验证结果
3. 提出**Saguaro 采样**，平衡接受率与缓存命中率
4. 相比推测解码实现**2 倍加速**，相比自归码实现**5 倍加速**

SSD 代表了 LLM 推理加速领域的重要突破，其核心思想——**预测验证结果以实现并行化**——为未来的推理优化研究提供了新的方向。

8 参考资料

1. Leviathan, Y., et al. (2023). Fast Inference from Transformers via Speculative Decoding. ICML.
2. Chen, C., et al. (2023). Accelerating Large Language Model Decoding with Speculative Sampling. arXiv.
3. Kumar, T., et al. (2026). Speculative Speculative Decoding. arXiv:2603.03251.